



并行计算研究的 结构化表达与可视化

Presenting Parallel Computing Research
From Problem Formulation to Evidence

学术汇报模板 · 版式与内容示例

汇报人：待填写 学号：待填写

哈尔滨工业大学

汇报日期：待填写

目 录

CONTENTS

01

问题与模型

02

实现与机制

03

图表与评价

04

讨论与结论

研究问题：并行度如何转化为端到端收益？

从工作负载定义研究对象

- **输入规模**：固定问题大小，讨论 strong scaling。
- **执行语义**：并行实现与串行实现完成相同计算。
- **评价边界**：明确传输、计算、同步分别是否计入。

可回答的问题

给定并行比例 f ，增加执行资源 p 的理论收益是多少？哪些额外成本需要进入实测模型？

让听众先知道优化对象、时间范围与判断标准，再进入实现细节。

 f

可并行工作占串行总时间的比例

 p

理想并行资源数量

本示例的曲线与数值来自解析模型，变量不绑定具体 GPU。

模型：串行部分给出了加速比的上限

固定问题规模的理想模型

$$T_p = T_1 \left((1 - f) + \frac{f}{p} \right)$$

$$S(p) = \frac{T_1}{T_p} = \frac{1}{(1 - f) + f/p}$$

$$\lim_{p \rightarrow \infty} S(p) = \frac{1}{1 - f}$$

该模型假设并行部分均匀分配，且忽略通信、调度和同步的额外成本。

符号与适用条件

符号	含义
T_1	串行总时间
T_p	使用 p 个资源的理想时间
f	可并行时间比例, $0 \leq f \leq 1$
$S(p)$	Speedup, 相同工作量下的时间比

公式负责定义关系；符号表负责降低理解成本；

注记负责限定结论范围。


方法对照：把决策依据放在同一张表中

组织方式	适合的工作	需要关注的成本	主要验证指标
Thread-per-task	独立且短小的任务	单线程状态量、访存合并	Register、带宽、吞吐
Warp-per-task	任务内存在协作	Lane 利用率、shuffle 成本	Warp efficiency、延迟
Block-per-task	较大协作范围	SMEM 容量、同步、占用率	SMEM、barrier stall
Pipeline	可分阶段的批量任务	提交、依赖、批次尾部	端到端时间、阶段重叠
对照维度保持一致		结论需要实测支持	

每行给出同一种信息，明确映射方式与工作负载的联系。

这些条目用于形成实验假设；具体配置的收益取决于输入与硬件。

流程图：用数据依赖组织实现说明



有向边表示依赖顺序；每个阶段的计时边界需要在实验中单独定义。

01 Input contract

输入类型、长度、布局 and 有效范围共同决定接口语义。

02 Parallel work

以明确的索引映射说明工作如何分配给线程。

03 Completion

输出有效性与完成时刻共同决定计时终点。

一张流程图对应一个抽象层次；并发关系与时间关系分别展开说明。

IMPLEMENTATION

把算法中的一次操作，
落实为线程中的一次访问。

代码与机制：一个线程负责一个有效元素

CUDA: element-wise vector addition

```
__global__ void add(const float* a,
                   const float* b,
                   float* c, size_t n) {
    const size_t i =
        size_t(blockIdx.x) * blockDim.x
        + threadIdx.x;
    if (i < n) {
        c[i] = a[i] + b[i];
    }
}
```

代码片段用于解释索引与访问关系。调用者负责分配有效设备缓冲区并检查执行状态。

三个阅读锚点

索引

$i = \text{blockIdx.x} \times B + \text{threadIdx.x}$

边界

$i < n$ 控制最后一个 block 的有效线程。

访问

相邻线程处理连续元素，形成相邻地址访问。

越界保护限定有效索引；输入、输出缓冲区仍需满足接口契约。

访存布局：用地址表解释连续访问

同一个 Warp 的前四个 Lane, 32-bit 元素

地址偏移 (Byte)	Lane 0	Lane 1	Lane 2	Lane 3
Stride = 1 element	0	4	8	12
Stride = 32 elements	0	128	256	384

计算规则

$$\text{offset}(\ell) = 4s\ell$$

ℓ 为 Lane 编号, s 为元素间距。地址表由公式直接计算。

与实测连接

使用内存事务、有效带宽与 Kernel 时间评估访问模式，并同时记录对齐条件。

内存事务数量还取决于参与 Lane、访问宽度、地址对齐和 GPU 架构。

机制说明：从局部计算走向完整执行路径

局部关系

- 连续地址访问影响访存事务。
- 线程状态影响 Register 需求。
- 协作范围影响同步方式。

局部机制用于解释观察结果。


完整路径

- 调用与数据准备进入计时边界。
- 传输与 Kernel 的依赖需要明确。
- 输出完成后才能计算端到端延迟。

最终指标覆盖用户实际等待的过程。

■ 当局部收益与总时间变化不一致时，使用阶段计时检查成本转移，并保持输入与配置一致。

Scaling curve: 串行比例限制资源扩展收益



先读趋势，再读边界

更高的并行比例带来更高的极限加速比。


$20\times$

$f = 0.95$ 时, $p \rightarrow \infty$ 的理论上限

曲线由 Amdahl 模型计算，假设额外开销为零。

图题表达结论；坐标和图注定义数值含义；正文解释对研究问题的影响。

Roofline: 让两个约束出现在同一张图中



归一化的解析关系

$$r = \min(1, x)$$

$$x = \frac{BI}{P_{\max}}, \quad r = \frac{P}{P_{\max}}$$

B : 带宽; I : 算术强度; $P_{\max}$: 计算上限。

图中仅展示模型约束。具体设备的上限需使用相应精度、指令类型和测量口径。

所有轴均为无量纲归一化量; 拐点 $x = 1$ 对应带宽约束与计算约束相交。

数值表：同一模型中的收益与效率

资源数量 p	归一化时间 T_p/T_1	Speedup $S(p)$	Efficiency $S(p)/p$
1	1.0000	1.000	100.00%
2	0.5250	1.905	95.24%
4	0.2875	3.478	86.96%
8	0.1688	5.926	74.07%
16	0.1094	9.143	57.14%
32	0.0797	12.549	39.22%

解析计算： $f = 0.95$, $T_p/T_1 = 0.05 + 0.95/p$ 。各列从未舍入数值独立取舍。

资源增加时，Speedup 与资源利用效率呈现不同变化；评价需要同时说明二者。

实验设计：把比较条件写到展示内容中

控制条件

条件	记录内容
----	------

输入	规模、分布、边界与随机种子
----	---------------

软件	Commit、Compiler、编译选项
----	----------------------

硬件	GPU 型号、显存、运行状态
----	----------------

计时	Warm-up、同步位置、重复次数
----	-------------------

输出证据

- 正确性：参考结果与边界输入检查。
- 性能：端到端延迟、吞吐与离散程度。
- 机制：阶段计时、资源与访问指标。

性能测量与机制分析分别记录运行配置，检查分析工具对执行时间的影响。

本页给出实验设计结构；在自己的报告中填入已执行的配置与结果文件位置。

讨论：收益需要覆盖新增成本

在 Amdahl 模型中加入额外时间

$$T_p^{\text{actual}} = T_1 \left((1 - f) + \frac{f}{p} \right) + T_{\text{overhead}}(p)$$

调度成本

提交、任务划分和依赖管理，
可能随资源或任务数量变化。

通信成本

数据移动、缓存行为和共享资源竞争，
需要结合路径分析。

同步成本

负载不均与完成时间分布会影响整体结束时刻。

优化成立的条件：节约的有效计算时间足以覆盖新增的执行成本。

适用范围：把结论和外推条件对应起来

当前模型给出的结论	成立条件	进一步研究需要补充
串行比例限制 Speedup 资源增加降低理想时间 Roofline 给出性能上界	固定问题规模, f 已知 完美负载分配, 额外成本为零 B 、 I 、 $P_{\max}$ 定义一致	工作量增长时的扩展模型 通信、调度与同步测量 指令、访存与并发限制

讨论页同时写清结论的支撑依据与适用范围, 让后续问题可以落到具体变量和实验上。

结论：问题、机制与证据形成完整链条

01

定义问题

说明输入、计算语义与评价边界，给出清晰的研究问题。

02

解释机制

用公式、代码和数据依赖说明映射方式及成本来源。

03

建立证据

让图表、实验条件与适用范围共同支撑最终判断。

每一页承担一个明确任务；每个关键判断都有可检查的依据。



感谢聆听 欢迎讨论

并行计算研究表达

附录 A：中英混排、公式与代码字体

正文层次

研究对象：GPU 上的批量并行计算

Global memory、Warp shuffle、Register pressure
和 Occupancy 使用一致的术语。

Source Sans 3 italic

Source Sans 3 bold / 思源黑体粗体

图注用于解释符号、条件与单位，重要信息随图表阅读。

数学与等宽字符

$$\mathbf{y} = \mathbf{A}\mathbf{x}, \quad \hat{a}_k = \sum_{j=0}^{n-1} a_j \omega^{jk}$$

```
size_t index = block * stride + lane;  
// 00 111 {} [] () <= >= !=
```

JetBrains Mono: 0123456789

中文正文使用思源黑体；西文使用 Source Sans 3；
代码使用 JetBrains Mono。

附录 B：注记色块随文字高度自适应

简短注记

■ 计时包含设备端同步。

两行注记

■ 此处 32 lanes 都参与 vote。Sign 的整轮 rejection 与这里的系数筛选分属不同层次。

关键结论

让注记紧邻它所解释的内容。

多行注记

■ 当说明包含条件、适用范围或计量单位时，左侧色块按整个文本盒的高度绘制。色块宽度为 2 pt，文字左侧间距为 1.5 mm，适用于不同列宽和自然换行。

内容与层次

注记用于补充影响理解的条件；浅蓝结论区用于承载本页要点。

重要条件随图表展示；文献、许可与详细证据放入随附文档或附录。

附录 C：长标题能够自然换行， 并保持内容区域与页面边界清晰

阅读顺序明确的三线表

内容类型	展示方式	常用命令
概念与条件	小标题、正文、注记	<code>\subhead</code> , <code>\notebox</code>
公式与符号	双栏与符号表	<code>columns</code> , <code>tabularx</code>
数值与趋势	矢量图、图注、指标	<code>\fig</code> , <code>\metric</code>
过程与实现	Mermaid、代码片段	<code>\includegraphics</code> , <code>lstlisting</code>

示例文件按主题分组；复制需要的 `frame` 即可复用相应版式。

附录 D：从最小文档开始组织自己的汇报

```
\documentclass[aspectratio=169,
  fontset=none]{ctexbeamer}
\usetheme{hit}
\title[Short title]{Chinese title}
\englishtitle{English title}
\begin{document}
\TitleSlide
\section{Problem}
\begin{frame}{A clear page title}
  Your content
\end{frame}
\end{document}
```

文件入口

example.tex：完整示例。

starter.tex：简洁起点。

fonts/：字体及原始许可。

README.md：构建与版式说明。

使用 XeLaTeX 编译，并保留主题、字体与所引用资源的相对目录结构。